JPDC 投稿稿件：作者审阅说明

题目：Parallelizing Quantized LLM Inference Under a Fixed Numerical Reference

本稿供作者审阅。写作、图表和 CPU 复算已经完成；最终作者信息、声明、数据存储与投稿决定尚未由作者确认。本轮没有运行新的模型或 GPU 实验，没有改动历史实验、基线或数据。

一页决策摘要

论文现在讲什么。 固定已有数值参考时，查询仍可以并行组织。方法把物理 KV 范围与投影的算术分组分开：在真正依赖范围的位置局部切分，保留其他宽图计算，并向消费者交付其预先要求的完整输出和后继状态。方法价值是这一构造及适用条件，不是把 packing、loop4、权重复用或固定归约分别声称为原创。

证据支持什么。 A5000、Qwen3-32B、target-only 的强同合同对照给出 1.51% 服务降时，95% 分层配对 root 区间为 1.23–1.79%。Q8 factorial 将 packing 的 0.80–1.64% 增量与很小的 LOCAL 增量分开。控制边界跨越显示明显机会，自然多轮两对话没有观察到 LOCAL 服务改善，扩大投机宽度会因额外工作使完整生成更慢。现代上游单输入提取算子在另一数值合同下快 38.7%，完整现代默认 backend 未运行。

当前稿件的定位。 这是固定参考条件下的并行执行方法与系统机制论文。JPDC 适配点是并行工作组织、实现条件和公平的系统性能解释；它不以“达到 5%”作为门槛，也不以较弱控制的大数字支撑主要方法增量。最强审稿风险仍是：可复用构造是否足够超越特定 llama.cpp 路径的工程组合，以及有限工作负载是否足以支持所选结论。正文主动给出构造、条件组合论证和反证，不能消除这些研究判断上的风险。

作者下一步。 可以审阅这份完整重构稿，优先确认方法新颖性的定位和结果解释。正式投稿前必须完成真实作者/资助/利益冲突/CRediT/AI 历史声明，决定适当的数据存储与受限访问条款，并复查投稿系统的最新要求。当前限定主张不要求为了追数字新增 GPU 面板。若希望声称完整现代后端优势、通用在线正确性保证或跨设备逐位一致，则需要新的实现与证据，当前稿件没有这些主张。

1. 叙事选择与原稿的关键变化

采用已经选定的“兼容并行执行方法”主线。机制分析解释方法为什么成立；成本与反例解释何时值得使用。题目按作者确定版本保留。HeteroSpec 只出现在既有仓库 URL 和真实相关文献题名中，不作为本文名称或新缩写。

引言先用四个已知查询的直观情境提出问题，再介绍两种分组。具体位置 765–768、物理范围 [768,768,768,1024] 及其构造留在方法节。结果节按“物理范围干预 → 强控制增量 → factorial 归因 → 几何机会和自然负结果 → 完整应用 → 更换合同的替代路径”展开。旧稿中以资格、阶段名和结果包为中心的叙事被移出正文。

方法定义消费者要求的输出集合、完整词表向量、canonical active KV 和逻辑状态。被排除的输出必须在运行前由消费者合同排除，不能发现不一致后再删除。组合论证明确依赖所用算子的数值义务；实现节区分在线检查、capture 观察、离线资格与条件论证，避免把有限实测扩大成一般证明。

与旧稿相比最重要的修正

原稿或早期表述风险	本稿处理	科学意义
32B 以 graph scalar-loop 的约 5.6% 为主要结果	主结果采用 C/B 的 1.51%；旧六臂面板保留在补充	显示共享量化之后的真正执行增量
将 S3 的 B 通称为 backend-loop4	明确为 backend scalar-loop，a=1；Q8 loop4 是 a=4	不把不同算术组织混成一个基线
完整投机收益与 packing/LOCAL 增量相邻但易混淆	主图分面显示 same-D4 增量和完整应用；补充保留全部 15 个固定对照	draft 及投机机制不被归给单一组件
LOCAL 的控制单元优势容易掩盖自然请求结果	同时显示 inside 负结果、低 crossing 频率、自然两对话及历史反转	解释机会频率与成本，而非挑选正例
packed 被读成继承 loop4 的完整 guard	明确普通 dispatcher、部署资格与 marked loop4 检查的差异	不制造不存在的在线安全证书
CLI 退出被扩大成事务恢复	区分 target poison 和进程退出；持久服务恢复列为实现缺口	保留真实失败边界
旧稿 6740/4784 精确资格总数缺少本轮直接 summary 追溯	主文撤出这两个精确计数；保留直接可核的 S3 资格深度和历史 reported 范围	不把旧正文数字冒充独立重比的原始证据
现代路径 38.7% 易被混作方法或服务收益	指明不同合同、单输入提取算子；完整 backend 明确未运行	允许数值迁移是更快的合理选择

固定参考的回归、重放和状态兼容用途以可信场景提出。没有虚构生产采用、客户需求或用户研究。其实际维护收益、能耗收益与迁移成本也没有被测量。

2. 核心主张、直接来源与边界

主张	支持层级与直接证据	必须保留的限制或反证
物理范围可改变 attention–value 的完整输出	固定 q=1 的 crop/pad 双向干预，源 [RANGE]	这是 AV 输出，不是该干预下完整 KV/状态的等价证明；Vulkan 是范围、layout 和 dispatch 联合修复
两种分组及局部切分可组成可复用构造	planner、native graph、F0 三臂源码、消费者所有权；源 [CODE]、[STRONG]、[GUARD]	算子义务是部署条件；没有自动发现等价 kernel 或跨输入证明

主张	支持层级与直接证据	必须保留的限制或反证
32B 执行组织比强同合同 B 降时 1.51%	12 roots × 4 rounds；六 coding/六 math 分层 bootstrap；源 [STRONG]、[ROWS]	target-only、固定 A5000 部署；144 fresh workers 各 warmup 后计时；不是常驻长生命周期并发服务
Q8 packing 与 LOCAL 的贡献不同	两模型四臂平衡 factorial；所有 root 和 family 区间；源 [ROWS]、[Q8F]	共用 16 roots；LOCAL/packed 的区间跨 1；k3 verification 至多四行，多组 packing 在 prefill
自然多轮未观察到 LOCAL 服务改善	两对话、两轮、四对、八个 episode；pooled L/W=1.042196；源 [NATURAL]	描述性结果，不给总体置信区间；不能推广为普遍更慢或更快
完整投机应用可改善 resident 计时	8B/14B/Llama 的所有固定 M 对照；源 [ROWS]	Llama worker 排名反转；32B 与 B570 的投机负结果保留；8B earlier D4 顺序固定
宽调用更便宜不意味着宽投机更快	equal-work q8 与 live k7/k3 分开；源 [WIDTH]	已知 token 操作与改变 proposal 工作量不是同一实验
现代 U 算子更快	事件时间/重复次数重算 U/B=0.612924；源 [MODERN]	不同合同、单张捕获输入；32766/32768 输出 bit patterns 不同；完整默认 backend [BACKEND] 未运行

S3 的主估计是每个 root 内平均 paired log ratio，再对 12 roots 等权几何平均，结果 0.9848637428511184。95% 区间 [0.9821479373132749,0.98772099465029]。pooled total ratio 为 0.9838094660308528，是不同 estimand。正文、图、摘要保持这一差别。

Q8 application/factorial 的点估计是 ratio of totals，使用 99% paired-root family intervals；interaction 是等权 root 的 ratio-of-ratios 几何均值。Windows live-width 用 98.75% intervals；B570 三配对用 observed range；自然 pilot 不造 CI。不同统计单位没有拼成一条统一曲线。

3. 图表设计：每张图承担一个论证任务

正文采用同一 P052 字体系统、蓝/赭/灰配色，颜色同时由形状、空实心、纹理或位置编码。PDF/SVG 是矢量，数值图直接从公开输入生成；PNG 只用于预览。主要图形文字按最终双栏尺寸检查。强控制、误差及负方向点没有被坐标轴裁掉。

图或表	设计意图	相对旧稿的变化与限制
主图 1：机制总览	三面板依次解释直接合批改变范围、两类分组、局部 attention 与输出/状态连接	新画；以具体行和分界替代工程术语框图。是正文机制图，不是 graphical abstract
主图 2：范围干预	四格直接比较两参考与 crop/pad 的输出身份	重画；显式 q=1 AV consumer、768/1024，避免把完整状态资格画成干预结果
主图 3：32B 强基线	12 roots 的重复点、root summary、95% C/B；旁列弱 G 的两次级对照	新增 S3；绝不让较大的 C/G 替代方法增量
主图 4：factorial	两模型小倍图，四个主效应与 interaction；灰点保留异质性	重画；明确 interaction 的不同 estimand，跨 1 区间保留
主图 5：几何机会	B570 crossing/inside 三配对及 A5000 机会频率分开显示	修改；不同量不共用“加速”轴，负 inside controls 和三点范围都可见
主图 6：应用与增量	分面比较 same-D4 与完整应用，使用各自合适的轴	重画；完整 15 个固定对照在补充可编辑表，不靠选择最快 M 代替预定 family

图或表	设计意图	相对旧稿的变化与限制
正文自然 pilot 表	两对话 × 两轮并排列出，pooled ratio 独立一行	新增；没有把重复测量变成四个独立任务，也没有把未测范围画成零
补图 D.1 / D.2：宽度与成本	equal-work、live-width、工作量，以及分阶段差额	重画；说明更少 cycles 为什么伴随更多 verified/draft rows
补图 E.1：历史几何	保留早期 16+16 等反转及未测格	重画；未测格明确留空，不补数
补图 C.1：早期 32B 与生命周期	保留旧六臂面板和 Llama 初始化反转	重画；旧弱 baseline 仍可查，但不再占据主结果
补图 E.2：RTX 合同取舍	C/C1/U 各会话独立显示，保留更慢旧合同候选	新增；旧 oracle 失败和未运行 backend 没有时间点

实际编号以最终 PDF 为准。每张图的固定源 URL、完整 commit、输入 SHA-256、图尺寸、输出 SHA-256、统计口径与脚本入口在 paper/generated/figure_manifest.json。编辑图形应改 build_figures.py 后重建，不手工移动数据点。

4. 独立审阅、修正与复算

写作与实现、文献/语言、图表/数据分别分工，之后交叉审阅整稿。主编直接阅读稿件和关键证据，没有把子任务总结当作原始数据。保留了审阅快照与逐项反馈，供作者检查发生了什么改动。

已落实的实质修正包括：算术分组先拆 full/tail 再 reshape，修复 r>0 的维度表达；“每部署已经证明”改成固定实现绑定及 reported-case 资格；factorial 不再暗示隔离 draft quality；S3 写明分层 bootstrap、fresh-worker 暖后计时；自然 pilot 从 two-request 改成 two-conversation；RTX B 明确为 extracted legacy packed Q8 operator；89-row 示例标明 proposed source-derived plan，不当作实测 launch 或自然 pilot 变慢的唯一原因。

CPU 复算重建 1568 条 Q8 服务/factorial timing rows、S3 288 行 warm/measured 记录和自然多轮八行；另外独立 NumPy 实现核对新公开的 928 行。所有对应点估计、区间和 interaction 与固定分析一致。绘图脚本执行 133 项数值断言并检查完整 root、配对和显示范围。它没有运行模型、native 资格或 GPU。

现代 RTX CSV 的 per_operator_ms 方便列存在约 1e-8 的比值舍入差异。图脚本使用同 CSV 的原事件时间除以批次重复数，准确重现公布结果。没有“修正”任何原始计时数据。

实际读取并应用的能力包括 scientific-writing、peer-review、literature-review、scientific-visualization、statistical-analysis，以及 blader/humanizer 4.0.0。科研 skill 固定到 K-Dense commit 2d2065fb4520fa3f3f2bcf61cff26ec8b7eba4b5；humanizer 固定到 b48c832f0f809c1b5658edbb838c2521b72f2413。环境自带 PDF 能力用于排版与实际渲染检查。未为凑数量安装软件，也未把不存在的技能列为使用记录。

审阅范围与未审范围

完整读取了现有论文源及补充、最新写作指南、当前重构稿和补充；核对了 main、#222、#241、#242 及相关结果 head 的关系。关键 planner、ownership、native graph lowering、loop4/packed dispatch、S3 diff 与 CPU consumer diagnostics 直接读源。现代上游重点核对 few-row、量化与 dispatch 路径；不是对全部 llama.cpp 的源码审计。主要文献按支持相应陈述的原始论文与官方源码阅读；文献清单记录了全文/局部/仅 metadata 的具体范围。

没有重新比较全部历史 native tensor bytes，没有重跑 GPU，没有审完整套形式证明或全部上游实现。部分历史资格总数只能回到旧论文，已撤出主文精确主张。公开 numeric projection 与原始 receipt 的区别在补充、数据 README 和来源 manifest 中说明。

5. JPDC 格式、构建和政策

投稿方向为 JPDC Regular，优先 subscription/non-OA；本轮没有选择 OA、购买选项或进行投稿。期刊范围与本研究的并行执行、性能评估和系统实现主题相符，但方法新颖性和证据充分性仍是审稿判断，不能据此承诺录用。

采用 [GUIDE] 中作者提供的官方摘录作为摘要、关键词、highlights 和页数约束：摘要不超过 250 词，关键词 1–7 个，独立 highlights 3–5 条、每条不超过 85 字符；双栏总页数按 16 页规划。当前摘要为 216 个空白分词，六个关键词，五条 highlights，字符数分别 82、84、84、77、85。完整在线 Guide 页面本轮再次访问返回 403；没有声称独立读到了其全部最新内容，正式提交前应复查。

官方 CAS ZIP 已从 Elsevier 官方 CDN 实际下载，SHA-256 为 36d97da01c6bbd134f315bff6c3de553735e2550444a6ddd4f869ddc67a20757，与 #242 完全相同。官方 cas-dc.cls 与 cas-common.sty 保持原字节。环境问题是 TeX 文件数据库/format/font map 缺失，已用本地 cache 修复并实际编译。使用 numeric natbib + unsrtnat，按出现顺序编号；CAS 原 bst 按作者排序，因此没有误用它。

正文采用可编辑双栏 CAS，补充独立编号 A–F，highlights 独立可编辑。自定义前导配置把模板默认“submitted to Elsevier”页脚替换为作者审阅稿，避免暗示已经投稿；未提供 ORCID 时不印空身份字段。官方模板类文件没有被改写。

官方 [LATEX] 指出 Editorial Manager 不处理含子目录的 LaTeX 源。交付同时保留便于维护的分目录源码和单层 submission source ZIP，并实际编译单层版本。它仍是供作者准备上传的文件，未自动上传投稿系统。

官方 [AI] 区分解释图、真实数据可复算图和 graphical abstract：本稿的机制图在图注说明 AI 辅助，数值分析/绘图在 Methods 说明，文末另有 AI declaration。当前环境报告的工具身份是 ChatGPT、OpenAI、GPT-6 Astra Pro；历史研究代码的完整 AI 工具、模型版本、用途和作者监督仍须作者核实。AI 声明没有声称作者已完成最终审查。

6. 最可能的审稿质疑与正面回应

为什么不直接换现代 backend? 如果允许改变数值合同，应当比较现代实现。稿件明确给出现代 U 的算子优势；研究问题是保留既有数值接口时如何组织工作。完整默认 backend 尚未测量，因此两者完整服务优劣是开放问题。这个回应保住问题定义，不证明每个部署都有保留旧参考的需求。

1.5% 为什么值得发表? 数值本身不能承担全部论文价值。它证明强同合同控制之后仍有可测增量；方法价值还来自两类分组、局部切分与消费者义务的构造，以及正负结果对机会和成本的解释。若审稿人认为组合仍过于特定实现，这个风险真实存在，不能靠弱基线的大数字解决。

是否只是补丁集合? 稿件提供输入条件、构造步骤、完整消费者关系和条件组合论证，并在 Q8 a=4、mixed-Q4/Q6 a=1 和 Vulkan 中给出不同实例。但没有自动准入、任意布局支持或通用数值证明。方法能否推广的判断仍需要读者评估；对更强推广主张应另做针对性实现与资格，而不是措辞升级。

正确性是否可靠且可复核? 全向量、active KV、逻辑前沿和消费者请求分别定义；CPU 反例说明 argmax 不足。公开计时可复算，关键源码可查。部分原始 native 数据受限或已裁减，当前没有完全开放的重执行承诺，这会影响可复现性评价。数据声明必须保持真实。

统计是否靠重复次数撑起来? S3 以 12 roots 分层推断，Q8 按 roots 聚类；显式标注复用 roots、固定顺序、置信区间 family、少样本范围和不同 estimand。没有把 48 pairs、1024 requests 或三次结构重复当作相同数量的独立任务。

7. 投稿前真正剩下什么

必做：无需新增 GPU

作者逐节确认科学判断、方法定位与局限；补齐真实单位/地址、通讯信息、CRediT、资助、利益冲突、致谢和最终 AI 声明。确认公开数据许可及公司限制的准确范围，决定满足 JPDC 数据要求的适当存储库和可合法提供的材料；已裁减材料不能承诺获取。复查最新完整 Guide、Regular 页数解释和投稿系统生成的 PDF。完成最终人为审阅并明确同意投稿后，才能去掉作者审阅草稿标记。

仅坚持更强主张时才需要

若要声称更快的完整现代 backend，需要同部署、完整计时边界且各自数值合同合格的比较；当前算子结果不足。如果要声称通用在线兼容或持久服务恢复，需要补齐 packed 实际 dispatch/placement guards 与全事务失效边界，再做针对性资格。如果要声称 LOCAL 对自然多轮普遍有效，需要独立代表性工作负载与机制可预测的机会分布；目前不建议为了追求百分比启动大面板。

可不做

无需为了达到 5% 扩大模型或平台规模；无需给每个旧结果重画一张主图；无需把所有历史工程日志塞进正文；无需改仓库名称来完成这篇无品牌标题的论文。旧仓库 URL 是来源，不是论文品牌。

直接来源

[RANGE] 固定 q=1 AV 物理范围干预。

[CODE] 当前 planner 固定源；native source snapshot 的完整成员 SHA 在方法来源表。

[STRONG] 32B 三臂代码与 S3 结果。

[ROWS] 公开原行、固定计划与复算程序。

[Q8F] 8B factorial；14B factorial。

[GUARD] 实现保证与观测边界。

[NATURAL] 自然多轮全部 episode。

[WIDTH] 宽度完整结果固定版本。

[MODERN] 现代 U 合同与全部算子原样本。

[BACKEND] 完整默认 backend 状态。

[GUIDE] #242 写作指南与官方模板固定 head；JPDC Guide for Authors。

[LATEX] Elsevier LaTeX instructions。

[AI] Elsevier generative AI policies for journals。

完整文献条目与固定版本在 paper/references.bib；实现、数据与文献的实际阅读范围在随附审阅记录中。正式稿的责任、真实作者声明和投稿选择留在作者决策点。